Il Metalinguaggio XML

Struttura, sintassi, esempi ed utilizzi

Francesco Gobbi

19 gennaio 2026

Cos'è XML

- XML = eXtensible Markup Language.
- È un **metalinguaggio**, cioè serve a definire altri linguaggi.
- Progettato per descrivere dati, non per visualizzarli.
- È indipendente da piattaforma e tecnologia.
- Basato su una sintassi rigorosa utile allo scambio di informazioni.

Obiettivi principali di XML:

- **Risolvere il problema della condivisione** dei dati tra piattaforme eterogenee.
- Permettere la **definizione della struttura dei dati** in modo standard.
- Favorire l'**interoperabilità tra sistemi e applicazioni**.
- Rendere i documenti leggibili sia da umani che da programmi.

Attenzione! XML non è...

- **HTML**: XML non definisce grafica o presentazione.
- **Java**: non esegue istruzioni, non contiene logica.
- **HTTP**: non è un protocollo di comunicazione.
- **MySQL**: non memorizza dati, li descrive.

XML come linguaggio formale

- Basato su una **grammatica formale** che definisce le regole sintattiche.
- Non possiede tag predefiniti: piena libertà di definizione.
- La struttura dei dati è descritta dall'utente.
- I tag hanno significato semantico, non grafico.

XML come metalinguaggio:

- Può essere usato per creare linguaggi personalizzati.
- Organizza i dati in maniera gerarchica.
- Permette rappresentazioni complesse tramite nested elements.
- Offre una sintassi universale per descrivere contenuti.

Caratteristiche dei file XML

- XML utilizza un **formato di file testuale**:
  - sia il markup sia il contenuto sono stringhe di caratteri;
  - il file è leggibile anche senza software specifici.
- I documenti XML si basano sulla codifica dei caratteri **ISO 10646** / **Unicode**.
- Questo garantisce un forte supporto alla **internazionalizzazione**:
  - è possibile scrivere documenti che mescolano alfabeti diversi;
  - non servono convenzioni o parametri esterni per riconoscere la lingua;
  - la codifica dei caratteri identifica automaticamente l'alfabeto usato.
- Un documento XML è **leggibile da un utente umano** anche senza la mediazione di applicazioni dedicate.

Utilizzi principali dell'XML

- Scambio dati Web $\rightarrow$ Server/Client.
- Integrazione applicazioni aziendali.
- Configurazione software (es. `web.xml` di Java EE).
- Memorizzazione strutturata all'interno dell'HTML (data islands).
- Generazione di documenti tramite XSLT.

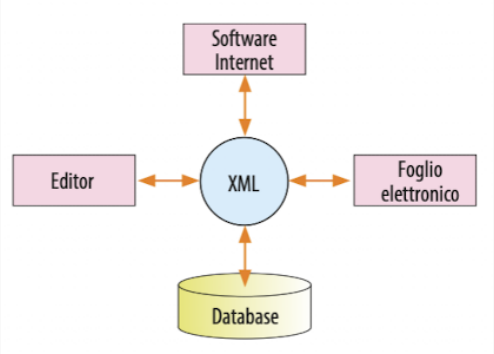

Vantaggi per lo scambio dei dati

- Riduce incompatibilità tra software.
- Evita conversioni multiple tra formati proprietari.
- Standard de facto dello scambio commerciale su Internet.
- Compatibile con database, fogli elettronici, editor.

Struttura di un documento XML: la Sintassi

- **Prologo**: dichiarazione XML + eventuali riferimenti.
- **Corpo**: contenuto strutturato tramite tag.
- Organizzazione gerarchica $\rightarrow$ albero.
- Un solo elemento radice (root).

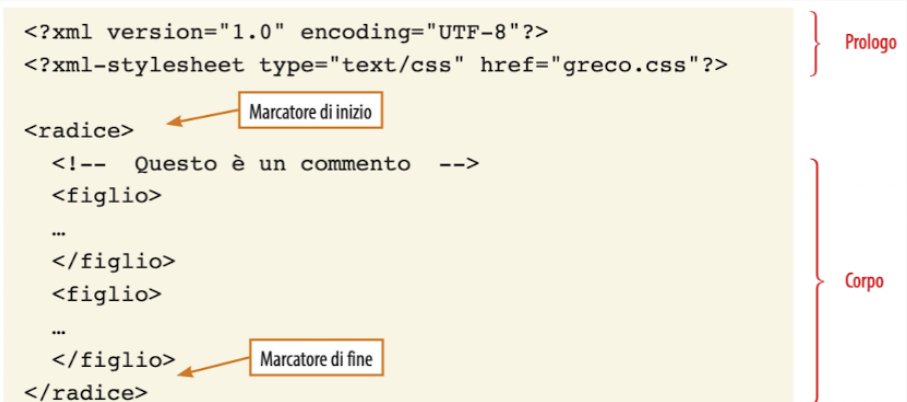


```
<?xml version="1.0" encoding="UTF-8"?>
<?xml-stylesheet type="text/css" href="greco.css"?>

<radice>
  <!--  Questo è un commento  -->
  <figlio>
  …
  </figlio>
  <figlio>
  …
  </figlio>
</radice>
```

XML Declaration: il Prologo

- Indica versione XML: es. `version="1.0"`.
- Indica codifica dei caratteri: es. `encoding="UTF-8"`.
- Parametro `standalone` specifica se è richiesto un DTD esterno (DTD = Document Type Definition).

```
<?xml version="1.0" ?>
<?xml version="1.0" encoding= "UTF-8"?>
<?xml version="1.0" encoding= "UTF-8" standalone="yes"?>
```

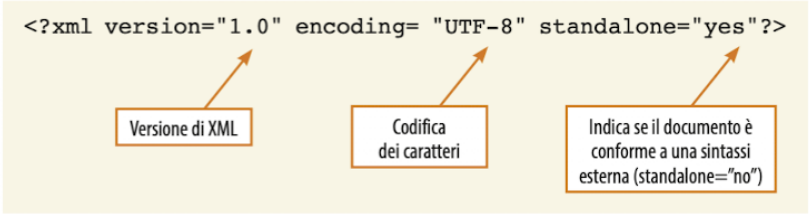

Regole sintattiche e regole semantiche

- In XML esistono **regole sintattiche**:
  - definiscono **come** scrivere correttamente un documento XML;
  - se non rispettate, il documento **non è XML valido per un parser**.
- Possono esistere anche **regole semantiche** (opzionali):
  - definiscono **cosa** è consentito scrivere (struttura attesa, elementi ammessi, ordine, tipi);
  - vengono fornite da una **grammatica** (es. XML Schema).

Ben formato (well-formed) vs Valido (valid)

Definizioni

- Un documento XML che rispetta le **regole sintattiche** è **ben formato**.
- Un documento XML che rispetta le **regole sintattiche** + **regole semantiche** è **valido**.

Relazione fondamentale

Un documento **valido** è **sempre ben formato**, ma un documento **ben formato** può **non essere valido**.

Regole di ben-formazione (1/2)

Un documento XML è ben formato se:

- contiene una **dichiarazione XML corretta** (se presente);
- il corpo ha **un unico elemento radice** (root), esclusi eventuali commenti;
- ogni elemento ha **tag di apertura e tag di chiusura**:
  - se l'elemento è vuoto si può usare la forma abbreviata `<nomeTag/>`.
- i tag sono **correttamente nidificati**:
  - chiusura in ordine inverso rispetto all'apertura (niente sovrapposizioni).

Regole di ben-formazione (2/2)

Un documento XML è ben formato se:

- i nomi dei tag di apertura e chiusura **coincidono perfettamente**
  - anche per **maiuscole/minuscole** (XML è **case-sensitive**).
- i nomi dei tag:
  - **non iniziano** con underscore (_) o con un numero;
  - **non contengono spazi**.
- i valori degli attributi sono sempre racchiusi tra **apici singoli o doppi**
  - es: `tipo="casa"` oppure `tipo='casa'`.

Errori tipici (ben-formazione)

- Tag non chiuso: `<nome>`
- Tag sovrapposti:
  - `<a><b></a></b`
- Maiuscole/minuscole diverse:
  - `<Titolo>...</titolo>`
- Più elementi radice:
  - `<a/> <b/>`
- Attributo senza virgolette:
  - `<x tipo=casa>`

Esempio: documento XML per una rubrica

- Obiettivo: rappresentare una rubrica con più persone.
- Elemento radice: `<rubrica>`.
- Elementi figli: `<persona>` con sotto-elementi (`<nome>`, `<cognome>`, `<telefono_casa>` ...).
- La prima riga può indicare versione XML e codifica dei caratteri (es. `ISO-8859-1` o `UTF-8`).

Ben formato o valido? (mini check veloce)

Checklist in 4 domande

1. C'è **un solo root**? (ben formato)
2. Tutti i tag sono **chiusi e nidificati**? (ben formato)
3. I nomi dei tag sono **coerenti e case-sensitive**? (ben formato)
4. Rispetta anche una **grammatica** (DTD/XSD)? (valido)

Idea chiave

Validità = ben-formazione + regole della grammatica.

Elementi XML

- Sono blocchi informativi identificati da un tag.
- Possono contenere testo o altri elementi.
- Possono essere espandibili senza limiti.
- Permettono strutture complesse e nidificate.

Documento XML per definire una rubrica

Supponiamo che si vogliano scambiare informazioni di database, per esempio un questionario compilato dagli utenti, su Internet utilizzando un browser e inviare al server tali informazioni. Questo processo richiede un formato che possa essere personalizzato per un utilizzo specifico. L'XML è la soluzione per questo tipo di problema: infatti, la rappresentazione visiva di un documento XML risulta elementare, come mostra l'esempio che segue.

```
<?xml version="1.0" encoding="ISO-8859-1"?>
- <rubrica>
  - <persona>
      <nome>Paolo</nome>
      <cognome>Camagni</cognome>
      <telefono_casa>0288888888</telefono_casa>
      <telefono_lavoro>02999999999</telefono_lavoro>
      <indirizzo_email>paolo@camagni.it</indirizzo_email>
    </persona>
  - <persona>
      <nome>Riccardo</nome>
      <cognome>Nikolassy</cognome>
      <telefono_casa>0277777777</telefono_casa>
      <telefono_lavoro>0299999999</telefono_lavoro>
      <indirizzo_email>riccardo@nikolassy.it</indirizzo_email>
    </persona>
</rubrica>
```

La prima linea del codice indica la versione dell'XML e il set di caratteri utilizzato: caratteri ISO- 8859-1 (Latin-1/West European). La riga successiva descrive l'elemento radice del documento (`rubrica`). L'elemento `rubrica` possiede come elemento figlio `persona` che a sua volta si compone di altri elementi figli (`nome`, `cognome`, `telefono`, `casa` ecc.).

Gerarchia degli elementi

- La struttura è un **albero**: radice → figli → sottofigli.
- Ogni elemento ha un solo padre.
- Gli elementi allo stesso livello sono "fratelli".